

Implementação *system calls* no kernel linux
V. 4.13.12

João Paulo de Oliveira joaopaulodeoliveira123@gmail.com
Lucas Rossi Rabelo lucasrossi98@hotmail.com
Matheus Pimenta Reis matheuspr96@hotmail.com

11 de dezembro de 2017

Sumário

Implementação System Calls no Linux

As *System Calls* fazem o interfaceamento entre o hardware e os processos do espaço de usuário, elas também servem para três propósitos principais:

1. Provém abstração com o hardware para que o usuário tenha um maior rendimento. Por exemplo, o usuário não se preocupa com o tipo de partição em que ele lerá um arquivo;
2. As *system calls* garantem a segurança e estabilidade para que um usuário relativamente leigo possa ter um alto rendimento com gerência de permissão, usuários e outros critérios de gerência do kernel;
3. Uma camada entre espaço de usuário e o resto do sistema permite fornecer o sistema virtualizado para os processos.

As chamadas syscalls em linux são, na maioria dos casos, acessadas pelas funções definidas na C library. As syscalls em si retornam um valor do tipo long4 que, quando negativo, em geral, denota um erro, já o retorno com valor zero (nem sempre) é um sinal de sucesso. A C library, quando uma *system call* retorna um erro, ela grava o código desse erro na variável global errno, que pode ser traduzida para um texto que fala sobre o erro através de funções de biblioteca.

Para a implementação de uma *system call* deve-se ter acesso ao código do kernel do sistema operacional para tanto, foi escolhido o kernel Linux que é open source.

Download do Kernel

Por ser open source, o código fonte do kernel do Linux é mantido online para livre acesso no GitHub(<https://github.com/torvalds/linux>), e também em The Linux Kernel Archives (<https://www.kernel.org/>) em várias versões e formatos de arquivos(compactados). A versão mais recente dada a data de início do TCD foi a versão **14.13.12** de gerência do kernel. A Free Software Foundation mantém, gerencia e presta suporte para o The Linux Kernel Archives. O download do kernel pode ser feito facilmente, além de outras funções com perguntas frequentes, download de versões em teste (beta)

para ser compilado em qualquer distribuição linux ou em outras plataformas que suportam o kernel. Como pode ser visto na imagem abaixo:



Figura 1: The Linux Kernel Archives: Local de download do Kernel

Compilação do kernel

Nesta seção vamos compilar o Kernel que previamente fizemos o Download para trabalhar com ele e assim poder criar nossas System Calls. Primeiramente precisamos instalar na nossa máquina um conjunto de ferramentas que nos permitira compilar nosso kernel, basta abrir seu terminal e digitar o seguinte comando:

```
sudo apt-get install libncurses5dev gcc make git exuberantctags
```

Criamos uma pasta no nosso espaço de trabalho, posteriormente extraímos todo o conteúdo do Kernel com o seguinte comando:

```
tar xvf linux*.tar.xz
```

onde * é a versão do kernel que acabamos de fazer o download neste caso usamos linux-4.13.12, então ficou

```
tar xvf linux-4.13.12.tar.xz
```

A seguir abrimos nossa pasta pelo terminal e acessamos onde está o kernel, fazendo uso do comando `cd`, que permite acessar um diretório.

Agora vamos compilar nosso kernel completamente, para isso basta usar o comando `make`, porém existe algumas opções bem úteis para agilizar o processo para isso usamos:

```
make -j4 CONFIG_LOCALVERSION="tutorial".
```

Ao usar o `-j4` estamos dizendo que o processo pode usar quantos processadores estejam disponíveis, no caso do exemplo são 4, ou seja, a máquina usada possui 4 processadores para realizar a tarefa, se sua máquina possuir 6, 8, etc você pode substituir pelo número de processadores da sua máquina, ou seja, `jX`, sendo `x` o número de processadores da sua máquina, vale ressaltar que se precisa usar a máquina durante o processo é recomendável deixar ao menos 1 processador para realizar suas atividades. Já o `"tutorial"` será o nome que seu kernel receberá após ser compilado e que você irá acessar quando estiver iniciando seu ubuntu, você pode alterar para o nome que desejar e fica entre `,` pois, é um conjunto de caracteres, este processo pode demorar, pois, é um processo extremamente grande, irá depender também da velocidade de processamento da máquina, em testes feitos pela nossas máquinas normalmente demorou entre 3 a 5 horas.

Quando por fim a compilação acabar precisamos substituir o kernel para assim que todas as modificações que fizermos posteriormente nele, possam ser carregadas com o sistema. Para isso abrimos o terminal vamos na pasta que criamos conforme a imagem anterior, e usamos os seguintes comandos:

```
make modules
```

```
sudo make modules_install
```

E por fim instalamos nosso novo kernel!, Este comando instala o Kernel, gera a imagem, copia os arquivos para o diretório `/boot` e atualiza o gerenciador de boot.

```
sudo make install
```

Agora está tudo pronto só precisamos acessar nosso novo kernel, para isso use no terminal o comando:

```
reboot
```

Quando estiver na opção de escolher o Sistema Operacional basta acessar opções avançadas do ubuntu e selecionar o seu kernel, que estará identificado pelo nome inserido no começo, vale ressaltar que quando você selecionar o kernel uma vez não é necessário selecionar-lo toda vez que der boot, a máquina pega o último kernel instalado.

Criação da System Call

A *system call* foi criada dentro na pasta kernel no diretório principal deixando o arquivo `scall.c` nessa pasta. Após isso foi adicionado o arquivo objeto no arquivo de *makefile* como descrito no tutorial, dessa forma, foi encontrada no arquivo `syscall_64.tbl` na forma:

333 common scall sys_det

Assim a função pode ser chamada pela função ***syscall(333)*** presente na *unistd.h*. Por fim, foi adicionado o cabeçalho da função no arquivo *syscall.h*. Depois disso foi compilado o kernel seguindo o tutorial proposto

```
unsigned long copy_to_user(void _user *to, const void *from, unsigned long n);
```

Vejamos agora o código do kernel utilizado para:

Tempo na CPU

Como primeira tentativa para obter o tempo de CPU de um processo, acessamos a variável *sum_exec_runtime* na estrutura *task_cputime*, com base nos comentários da estrutura, concluímos que tal variável era o que desejávamos como segue na figura 2:

```
--  
/**  
 * struct task_cputime - collected CPU time counts  
 * @utime:           time spent in user mode, in nanoseconds  
 * @stime:           time spent in kernel mode, in nanoseconds  
 * @sum_exec_runtime: total time spent on the CPU, in nanoseconds  
 *  
 * This structure groups together three kinds of CPU time that are tracked for  
 * threads and thread groups. Most things considering CPU time want to group  
 * these counts together and treat all three of them in parallel.  
 */  
struct task_cputime {  
    u64                               utime;  
    u64                               stime;  
    unsigned long long                sum_exec_runtime;  
};  
  
/* Alternate field names when used on cache expirations: */  
#define virt_exp                      utime  
#define prof_exp                      stime  
#define sched_exp                    sum_exec_runtime
```

Figura 2: Estrutura *task_cputime*

No entanto, com a tentativa não obtivemos o resultado esperado. como segunda tentativa, encontramos uma função chamada `get_sum_exec_runtime`. Apartir de ai decidimos usar o que a função fornece, ou seja, chamar direto na propria task o desejado usando esse "su" que posteriormente seria a `shed_entity` como segue a imagem:

```

struct sched_entity {
    /* For load-balancing: */
    struct load_weight    load;
    struct rb_node        run_node;
    struct list_head      group_node;
    unsigned int          on_rq;

    u64                   exec_start;
    u64                   sum_exec_runtime;
    u64                   vruntime;
    u64                   prev_sum_exec_runtime;

    u64                   nr_migrations;

    struct sched_statistics statistics;
}

```

Figura 3: Parte da estrutura `sched_entity`

Que é o resultado que procuravamos, decidimos usar direto pois chamar uma função pode ser menos eficiente que chama-la na propria `task_struct` assim obtemos em nano-segundos o tempo que o processo passou pela CPU.

Tempo de vida do processo

O tempo de vida do processo não pode ser extraído diretamente, assim a estratégia adotada foi usar a variável interna à `task_struct`, a `start_time` presente na `shed.h`, que é o tempo em nanosegundos contando apartir do boot da máquina (Monotonic): A outra variável usada foi a função `ktime_get_boottime()`

```

725
726      /* Monotonic time in nsecs: */
727      u64 start_time;

```

Figura 4: `start_time`: Tempo de vida do processo em nanosegundos contando apartir do boot

presente em *linux/timekeeping.h*. Essa função retorna, intuitivamente, o *boot time* que é o tempo em que a máquina está ligada, desde de o boot até o momento atual. Tendo essas duas variáveis, a *start_time* foi subtraída do retorno da função **ktime_get_boottime()**, como se segue na figura. Assim foi possível obter o tempo de vida do processo.

Nº de vezes que o processo passou pela CPU

Verificando a *task_struct* percebimos que tinha uma estrutura que nos auxiliaria chamada *shed_info* como segue na figura 5:

```
struct sched_info {
#ifdef CONFIG_SCHED_INFO
    /* Cumulative counters: */

    /* # of times we have run on this CPU: */
    unsigned long          pcount;

    /* Time spent waiting on a runqueue: */
    unsigned long long     run_delay;

    /* Timestamps: */

    /* When did we last run on a CPU? */
    unsigned long long     last_arrival;

    /* When were we last queued to run? */
    unsigned long long     last_queued;

#endif /* CONFIG_SCHED_INFO */
};
```

Figura 5: Sched_info

basta retornar o *pcount* que obteremos o resultado desejado

Código da system call

Segue o código:


```

#include <linux/linkage.h> //Syscall espera argumento da pilha
#include <linux/kernel.h> //Printk
#include <linux/pid.h> //pid_task(), PIDTYPE_PID
#include <linux/sched.h> //task_struct
#include <linux/uaccess.h> //copy_to_user
#include <linux/timekeeping.h> //ktime_get_boottime()

asmlinkage long sys_det(int pid, long int *n_in_CPU, long int *CPU_time, long long int *lifetime){
    struct task_struct *task = NULL;
    long long int life;
    task = pid_task(find_vpid(pid), PIDTYPE_PID);

    if(task == NULL)
        return -1;
    else{
        printk("O pid eh %d\n",task->pid);

        life = ktime_get_boot_ns() - task->start_time;

        if(copy_to_user(n_in_CPU ,&(task->sched_info.pcount),sizeof(long int)))
            return -1;

        if(copy_to_user(lifetime ,&life,sizeof(long long int)))
            return -1;

        if(copy_to_user(CPU_time ,&(task->se.sum_exec_runtime),sizeof(long int)))
            return -1;

        printk("Quantidade de vezes que o processo %d passa pela CPU: %ld\n",task->pid ,*n_in_CPU);
        printk("Time CPU: %ld\n",*CPU_time);
        printk("Tempo de vida do processo: %lld s\n", *lifetime);
    }
    return 0;
}

```

Figura 6: Código da system call

Foi usada também a função `copy_to_user` para copiar um bloco de dados do kernel para o espaço de usuário para que a função possa retornar por parâmetro

Programa usuário da system call

```

#include<stdio.h>
#include<linux/kernel.h>
#include<sys/syscall.h>
#include<unistd.h>
#include<errno.h>
int main(){
    int x,y;
    printf("Digite um pid: ");
    scanf("%d",&y);

    long int ncpu, cputime;
    long long int lifetime=0;

    x = syscall(333, y, &ncpu, &cputime, &lifetime);
    if(x == 0)
        printf("Numero de vezes na CPU: %ld\n Tempo na do processo na CPU: %ld\n Tempo de vida do processo: %lld\n",ncpu, cputime,lifetime);
    else return -1;
}

```

Figura 7: Código para chamar system call